Московский авиационный институт (национальный исследовательский университет)

Институт информационных технологий и прикладной математики
«Кафедра вычислительной математики и программирования»

Лабораторная работа №4
по предмету "Дискретный анализ"

Студент: Елистратова П.А.
Преподаватель: Макаров Н.К.
Группа: М8О-210Б-21
Дата:
Оценка:
Подпись:

Москва 2023 г.

Оглавление

Цель работы

Реализовать алгоритм поиска построки в строке на Си++.

Постановка задачи

Необходимо реализовать поиск одного образца в тексте с использованием алгоритма Z-блоков. Алфавит — строчные латинские буквы.

Формат ввода

На первой строке входного файла текст, на следующей — образец. Образец и текст помещаются в оперативной памяти.

Формат вывода

В выходной файл нужно вывести информацию о всех позициях текста, начиная с которых встретились вхождения образца. Выводить следует по одной позиции на строчке, нумерация позиций в тексте начинается с 0.

Описание

Для строки S и позиции i > 0 определим:

$Z_i(S)$ — длина наибольшей подстроки S, которая начинается в i и совпадает с префиксом S.

Z-блок в i, для которого Zi > 0 — интервал, начинающийся в i и кончающийся в позиции $i + Z_i - 1$.

r_i — крайний правый конец Z-блоков, начинающихся не позднее позиции i, то есть наибольшее значение $i + Z_i$ — 1 по всем $0 < j \le i$, для которых $Z_j > 0$.

Реализация

Считаем сначала заданный текст, а затем паттерн. Добавим наш текст в вектор к паттерну, разделив их символом «$». Идея алгоритма заключается в том чтобы посчитать Z-функцию для объединённых паттерна и текста, и тогда если какое-то Z_i равно длине паттерна, значит с позиции i мы имеем полное вхождение нашего паттерна в текст.

Алгоритм вычисления Z-функции следующий:

Будем поддерживать координаты [left; right] самого правого Z-блока. Тогда если текущий индекс, для которого мы хотим посчитать очередное значение Z-функции, — это i, мы имеем один из двух вариантов:

i > right— т.е. текущая позиция лежит за пределами того, что мы уже успели обработать. Тогда будем вычисляем функцию тривиальным алгоритмом.

i ≤ right — т.е. текущая позиция лежит внутри отрезка совпадения [left; right] . Тогда мы можем использовать уже подсчитанные предыдущие значения Z-функции. Дальше снова действуем тривиальным алгоритмом — потому что после границы r могло обнаружиться продолжение Z-блока.

Код программы

lab4.cpp

```
#include <iostream>
#include <stdio.h>
#include <string.h>

template <typename T>
class VectorClass
{
    T* data;
    int capacity;
    int current;

public:
    VectorClass()
    {
        data = new T[1];
        capacity = 1;
        current = 0;
    }
    ~VectorClass()
    {
        delete[] data;
    }

    void push(T value)
    {
        if (current == capacity)
        {
            T* temp = new T[2 * capacity];

            for (int i = 0; i < capacity; i++)
            {
                temp[i] = data[i];
            }

            delete[] data;
            capacity *= 2;
            data = temp;
        }

        data[current] = value;
        ++current;
    }

    void push(T value, int index)
    {
        if (index == capacity)
        {
            push(value);
        }
        else
        {
            data[index] = value;
        }
    }

    T get(int index)
    {
        return data[index];
    }
```

```
    int size()
    {
        return current;
    }
};

int* ZFunction(VectorClass<char> &s, int* Z)
{
    int n = s.size();
    int left = 0;
    int right = 0;

    for (int i = 1; i < n; ++i)
    {
        if (i < right)
        {
            if (right - i < Z[i - left])
            {
                Z[i] = right - i;
            }
            else
            {
                Z[i] = Z[i - left];
            }
        }

        while (s.get(Z[i]) == s.get(i + Z[i]))
        {
            Z[i] += 1;
        }

        if (i + Z[i] > right)
        {
            left = i;
            right = i + Z[i];
        }
    }
    return Z;
}

int main()
{
    VectorClass<char> P;
    VectorClass<char> T;
    char symbol;

    while ('\n' != (symbol = getchar()))
    {
        T.push(symbol);
    }

    while ('\n' != (symbol = getchar()))
    {
        P.push(symbol);
    }

    int n = P.size();
    int m = T.size();
    P.push('$');

    for (int i = 0; i < T.size(); ++i)
    {
```

```
        P.push(T.get(i));
    }

    int Z[n + m + 1];
    memset(Z, 0, (n + m + 1) * sizeof(int));
    ZFunction(P, Z);

    for (int i = 0; i < n + m + 1; ++i)
    {
        if (Z[i] == n)
        {
            std::cout << i - n - 1 << "\n";
        }
    }

    return 0;
}
```

Пример работы

```
polina@pelis:~/diskran/lab4$ cat input.txt
abacaba
ab
polina@pelis:~/diskran/lab4$ g++ lab4.cpp
polina@pelis:~/diskran/lab4$ ./a.out < input.txt
0
4
```

Сравнения производительности

Сравним алгоритм поиска подстроки в строке с помощью Z-блоков с наивным алгоритмом. По оси X — количество входных символов, по оси Y — время в мс. Голубой график — наивный алгоритм, оранжевый график — с использованием Z-функции.

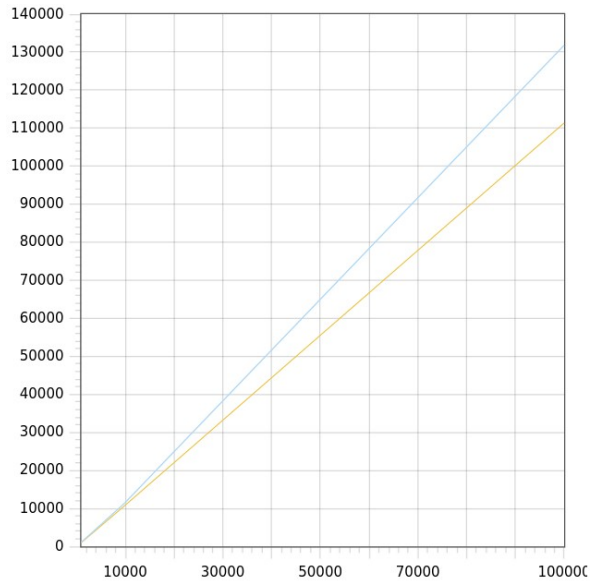

Как мы видим, алгоритм поиска подстроки в строке с помощью Z-блоков работает быстрее. Конечно, потому что не приходится повторно сравнивать

символы в случаях, когда для ускорения расчёта Z-функции мы можем использовать уже вычисленные значения.

Вывод

Выполнив данную лабораторную работу, я реализовала алгоритм поиска подстроки в строке. Построение Z-функции работает за O(n+m), где n — длина паттерна, а m — длина текста, а поиск всех вхождений работает за O(m). Это гораздо эффективнее наивного алгоритма, который в худшем случае работает за O(n*m). Также положительной чертой этого алгоритма, является то, что он относительно прост для понимания.